

Plano de Análise Estatística (PAE)

Título: Fonte de Água e Doença Diarreica: Um Estudo de Coorte Prospectivo numa População Distrital Simulada

Investigador Principal: Arsénio Nhacolo

Evento: Hackathon Lusófono da AMMnet

Data: 2026-06-10

Versão: 1.0

1. Objectivos do Estudo

1.1 Objectivo Principal

Estimar e comparar a incidência de diarreia entre indivíduos que utilizam água de poço versus água de torneira como principal fonte de água doméstica.

1.2 Objectivos Secundários

1. Descrever as características sociodemográficas e domésticas basais da coorte do estudo, estratificadas por fonte de água.
2. Estimar a incidência acumulada (risco) de diarreia (pelo menos um episódio durante o seguimento).
3. Estimar a taxa de incidência global de diarreia (contabilizando os episódios recorrentes e o tempo total de pessoa).
4. Estimar as medidas de associação brutas e ajustadas (Razões de Risco, Razões de Taxa, Razões de Risco Instantâneo (Hazard Ratios) e Razões de Odds) comparando o grupo exposto (água de poço) e não exposto (água de torneira).
5. Realizar uma análise de sobrevivência do tempo até ao primeiro episódio.

2. Variáveis e Definições de Dados

A análise utilizará o conjunto de dados `wsdd_data.csv`. As variáveis são definidas do seguinte modo:

Nome da Variável	Descrição	Tipo de Dados	Operacionalização e Codificação
<code>id</code>	ID do Participante	Inteiro	Identificador sequencial (1–1.200)
<code>enrolment_date</code>	Data de recrutamento	Data	Formato de data (AAAA-MM-DD); usado para avaliar

Nome da Variável	Descrição	Tipo de Dados	Operacionalização e Codificação
			sazonalidade ou tendências seculares
age	Idade no recrutamento	Inteiro	Contínua (1–85 anos); será modelada continuamente e categorizada se não linear
sex	Sexo biológico	Factor	Binária: 0 = Masculino (ref), 1 = Feminino
water_source	Fonte de água principal	Factor	Binária: 0 = Água de torneira (ref), 1 = Água de poço
sanitation	Acesso a saneamento melhorado	Factor	Binária: 0 = Não (ref), 1 = Sim
household_size	Tamanho do agregado familiar	Inteiro	Contínua (1–15)
socioeconomic_status	Nível socioeconómico	Factor	Ordinal: 1 = Baixo (ref), 2 = Médio, 3 = Alto
education_head	Escolaridade do chefe da casa	Factor	Ordinal: 1 = Nenhuma (ref), 2 = Primário, 3 = Secundário, 4 = Terciário
num_episodes	Número total de episódios	Inteiro	Contagem (0, 1, 2, ...); usado para taxas de incidência e modelação de eventos recorrentes
time_to_first_episode	Tempo até ao primeiro episódio	Inteiro	Contínua (1–365 dias); censurada no follow_up_time se não ocorreu nenhum episódio
follow_up_time	Tempo total de seguimento	Inteiro	Contínua (1–365 dias)
lost_to_follow_up	Estado de perda de	Factor	Binária: 0 =

Nome da Variável	Descrição	Tipo de Dados	Operacionalização e Codificação
	seguimento		Concluído (ref), 1 = Perdido

2.1 Variáveis Derivadas

- **Estado de Diarreia (diarrhoea_status):** Uma variável binária que indica se o participante teve pelo menos um episódio de diarreia durante o período de seguimento.

$$\text{diarrhoea_status} = \begin{cases} 1 & \text{se num_episodes} > 0 \\ 0 & \text{se num_episodes} = 0 \end{cases}$$

- **Tempo Líquido de Pessoa em Risco (Dias):** O tempo de seguimento ajustado através da subtração do tempo em que o participante esteve activamente doente. Seguindo suposições clínicas, assume-se que cada episódio de diarreia dura em média 3 dias.

$$\text{net_person_time_days} = \text{follow_up_time} - (\text{num_episodes} \times 3)$$

- **Tempo de Pessoa em Risco (Anos):**

$$\text{person_time_years} = \frac{\text{net_person_time_days}}{365,25}$$

3. Limpeza de Dados e Pré-processamento

Antes da análise estatística, a limpeza de dados será realizada no script `s01_clean_data.r`. Serão implementadas as seguintes verificações e acções:

- **Inconsistências Lógicas:**
 - Verificar se `num_episodes > 0` mas `time_to_first_episode` é NA (ou vice-versa).
 - Verificar se `time_to_first_episode > follow_up_time`.
 - Verificar se `lost_to_follow_up = 0` mas `follow_up_time < 365`.
 - Verificar a existência de valores negativos na idade, tamanho do agregado familiar ou tempo de seguimento.
- **Reclassificação de Factores (Re-leveling):**
 - Todas as variáveis categóricas serão explicitamente convertidas em factores. Os níveis de referência serão definidos usando o pacote `{forcats}` para representar o grupo não exposto ou de menor risco (por exemplo, Água de torneira para exposição, Masculino para sexo, Baixo para nível socioeconómico).

4. Métodos Estatísticos

4.1 Análise Descritiva

As características demográficas e do agregado familiar basais serão descritas e estratificadas por `water_source`.

- **Variáveis Contínuas:** Resumidas como média (Desvio Padrão, DP) para variáveis com distribuição normal, ou mediana (Intervalo Interquartil, IQR) para variáveis com distribuição assimétrica. As comparações estratificadas utilizarão o teste t para amostras independentes ou o teste de soma de postos de Wilcoxon.
- **Variáveis Categóricas:** Resumidas como frequências (n) e percentagens (%). As comparações utilizarão o teste do Qui-quadrado ou o teste exacto de Fisher (se as contagens de células forem < 5).
- **Relatório:** Uma Tabela 1 basal será gerada usando `gtsummary::tbl_summary` com uma coluna global e relatório explícito de dados em falta (`missing = "ifany"`).

4.2 Análise Primária: Estimativas Brutas

- **Incidência Acumulada (Risco):**
 - Proporção de incidência acumulada comunicada globalmente e estratificada por fonte de água com Intervalos de Confiança (IC) de 95% binomiais exactos (Clopper-Pearson).
 - **Razão de Risco (RR):** Calculada como o risco no grupo da água de poço dividido pelo risco no grupo da água de torneira, com IC de 95% de Wald.
- **Taxa de Incidência (TI):**
 - Taxa de incidência calculada globalmente e estratificada por fonte de água como o número total de episódios dividido pelo tempo total de pessoa em risco em anos, expressa por 1.000 pessoas-ano, com IC de 95% de Poisson.
 - **Razão de Taxas de Incidência (RTI):** Calculada como a taxa no grupo da água de poço dividida pela taxa no grupo da água de torneira, com IC de 95% de Poisson.

4.3 Modelação Multivariável e Ajuste de Factores de Confusão

Para controlar a confusão, as covariáveis serão seleccionadas a priori com base no conhecimento clínico e plausibilidade epidemiológica. Não serão utilizados métodos automatizados de selecção de variáveis (stepwise). Os factores de confusão ajustados incluirão: `age`, `sex`, `sanitation`, `socioeconomic_status` e `education_head`.

- **Risco de Diarreia (Desfecho Binário):**
 - **Modelo:** Regressão Logística Multivariável.
 - **Estimativas:** Razões de Odds ajustadas (aOR) com ICs de 95% de verosimilhança do perfil.

- **Alternativa (para Estimativa Directa da Razão de Risco):** Regressão log-binomial multivariável ou regressão de Poisson com erros padrão robustos (estimador sandwich) para calcular Razões de Risco ajustadas (aRR).
- **Taxa de Diarreia (Desfecho de Contagem):**
 - **Modelo:** Regressão Binomial Negativa (preferível em relação à regressão de Poisson padrão se houver sobredispersão, a qual será avaliada usando o teste do parâmetro de dispersão).
 - **Offset:** $\log(\text{person_time_years})$ será incluído como termo de offset.
 - **Erros Padrão Robustos:** Como os participantes podem ter eventos recorrentes, calcularemos erros padrão robustos para contabilizar a correlação intra-indivíduo.
 - **Estimativas:** Razões de Taxas de Incidência ajustadas (aRTI) com ICs de 95%.

4.4 Análise de Sobrevivência (Tempo-até-ao-Evento)

Para modelar o tempo desde o recrutamento até ao primeiro episódio de diarreia:

- **Estimador de Kaplan-Meier:** Curvas de sobrevivência que mostram a probabilidade de permanecer livre de diarreia ao longo do tempo, estratificadas por `water_source`. As diferenças estatísticas serão avaliadas usando o teste de log-rank.
- **Regressão de Riscos Proporcionais de Cox:**
 - Os modelos de Riscos Proporcionais (RP) estimarão as Razões de Risco (Hazard Ratios) brutas e ajustadas (HR, aHR) e respectivos ICs de 95%.
 - **Verificação do Pressuposto de RP:** Testado através dos resíduos de Schoenfeld via `survival::cox.zph()`. Se o pressuposto for violado para alguma covariável, serão introduzidos modelos de Cox estratificados ou covariáveis dependentes do tempo.

4.5 Diagnósticos e Colinearidade

- A multicolinearidade entre os preditores será avaliada utilizando o Factor de Inflação de Variância (VIF) dos modelos logístico e de sobrevivência. Um VIF > 5 justificará uma investigação detalhada.

5. Tratamento de Dados em Falta

- **Avaliação:** Os padrões de dados em falta serão visualizados usando o pacote `nanian::vis_miss()`.
- **Estratégia:**
 - A análise de casos completos (complete-case) servirá como abordagem primária.
 - Se a proporção de dados em falta nas covariáveis chave (por exemplo, `education_head`, `socioeconomic_status`) exceder 5%, será realizada

Imputação Múltipla por Equações Encadeadas (`mice::mice()`) como análise de sensibilidade. Serão gerados dez conjuntos de dados imputados e os resultados dos modelos combinados utilizando as regras de Rubin.

6. Padrões de Apresentação e Relatório

- **Valores-p:** Comunicados com 3 casas decimais (por exemplo, $p = 0,024$). Valores-p inferiores a 0,001 serão apresentados como $p < 0,001$.
- **Tamanhos de Efeito:** Todos os resultados de regressão serão acompanhados pelos respectivos tamanhos de efeito relativo (aOR, aRR, aRTI, aHR) e correspondentes ICs de 95%.
- **Visualizações:** Os gráficos serão criados com o pacote `ggplot2` usando paletes adequadas para daltônicos (por exemplo, `scale_color_viridis_d()`) e o tema `theme_minimal()`. Os gráficos de Kaplan-Meier incluirão tabelas de risco usando `survminer::ggsurvplot`.
- **Reprodutibilidade:** A sintaxe do código será formatada através de `styler::style_dir()` e auditada usando `lintr::lint_dir()`. As informações da sessão de R serão anexadas a todos os relatórios finais para registrar as versões dos pacotes.